

# Open Source Software como Herramienta en la Reproducibilidad de la Investigación

Danilo Dominguez Perez, PhD.

# Acerca de mí

- Danilo Domínguez Pérez
- Estudios
  - Egresado de la UTP - Ing. en Sistemas y Computación
  - Maestría en Ciencias Computacionales del Rochester Institute of Technology
  - Doctorado en Ciencias Computacionales de Iowa State University
    - Investigación en Análisis y Testing de Aplicaciones Móviles
- Miembro de 
- Ingeniero de Software Móvil en Automattic 



<https://www.linkedin.com/in/danilo-dominguez-perez>



@danilo04



@danilo04

# Investigación Científica

- Proceso creativo y sistemático
- Ayuda a aumentar el conocimiento actual
- Implica recopilación, organización y análisis de información




# Investigación Científica

- Proceso creativo y sistemático
- Ayuda a aumentar el conocimiento actual
- Implica recopilación, organización y análisis de información
- Aplicación del método científico
- Diferentes tipo de investigación
  - Tecnológica
  - Cultural
  - etc.



# Proceso Científico

- Los logros de la investigación se pueden ver palpables desde el Internet, GPS, vacunas, etc.
- Todo este logro es acumulativo y depende de un tejido de confianza en el proceso científico



# Proceso Científico

**¿Cómo nos aseguramos que los resultados de los experimentos son correctos?**



# Reproducibilidad en la Investigación Científica

- Imaginense darle 1 receta a 10 chefs y obtener 10 platos diferentes
- Hay diferentes factores y variables que contribuyen a la inconsistencia
- Lo mismo aplica para experimentos científicos

**Una manera que se utiliza para validar estudios científicos es repetir la investigación que lo produjo**

# El Artículo Científico

- Se utilizan para compartir su propio trabajo de investigación original con otros científicos o para revisar la investigación realizada por otros
- Suelen publicarse en un periódico llamado journal cuyo propósito es publicar este tipo de trabajos
- Normalmente presentan el método de experimentación completo, los resultados y el análisis de los mismos
- **Fuente principal para entender y reproducir estudios**

**A Cognitive Model for the Representation and Acquisition of Verb Selectional Preferences**

Afra Alshabani  
Department of Computer Science  
University of Toronto  
[afrase@cs.toronto.edu](mailto:afrase@cs.toronto.edu)

Suzanne Stevenson  
Department of Computer Science  
University of Toronto  
[suzanne@cs.toronto.edu](mailto:suzanne@cs.toronto.edu)

**Abstract**

We present a cognitive model of inducing verb selectional preferences from individual verb usages. The selectional preferences for each verb argument are represented as a probability distribution over the set of semantic properties that the argument can possess – a semantic profile. The semantic profiles yield verb-specific conceptualizations of the arguments associated with a syntactic position. The proposed model can incrementally learn verb selectiveness from a small set of noisy training data, and can then in simulate learning plausibility judgments and applying implicit object alternation.

**1 Introduction**

Verbs have preferences for the semantic properties of the arguments filling a particular place. For example, the verb *eat* tends to take objects that are edible, among others. Learning verb selectional preferences is an important aspect of human language acquisition, and the acquired preferences have been shown to guide children's expectations about missing or upcoming information in language comprehension (Nation et al., 2005).

Rensink (1996) introduced a statistical approach to learning and use of verb selectional preferences. In this paper, we introduce a more clear hierarchy for this use, together with an incremental model to induce a verb's selectional preferences for a particular argument position in the form of a distribution

over all the classes that can occur in that position. Rensink's model was proposed as a model of human learning of verb selectional preferences through individual representations of usages. It showed how such preferences could be acquired from usage data and an existing conceptual hierarchy. However, his and later computational models (see Section 2) have presented two difficulties making certain cognitive properties critical for a child language acquisition model. All these models use the training data in "batch mode", and most of them use some information theoretic measures that rely on total counts from a corpus. These measures are not clear how the representations of individual predicates should be incrementally learned in these models as the system receives more data. Moreover, the assumption that children have access to a full hierarchical representation of semantic classes may be too strict. We propose an alternative view in this paper which is more plausible in the context of child language acquisition.

In this paper, we extend the work of Alshabani and Stevenson (2005). We have proposed a language-based computational model of early verb learning that uses Bayesian clustering and prediction to model language acquisition and use. Individual verb usages are incrementally grouped to form semantic profiles, and linguistic constraints are used to share semantic and syntactic properties. We have shown that our Bayesian model can incrementally acquire a general conception of the semantic roles of predicates based only on exposure-induced changes in the semantic profile. This is in contrast to other approaches which learn selectional preferences in batch mode. Here we have only reported the results for the final stage of learning, but the model allows us to monitor the semantic

41

Proceedings of the Workshop on Computational Aspects of Computational Language Acquisition, pages 41–48,  
Prague, Czech Republic, June 2007 © 2007 Association for Computational Linguistics

| Alternating verbs | Non-alternating verbs |
|-------------------|-----------------------|
| write             | hang                  |
| sing              | open                  |
| drink             | say                   |
| eat               | catch                 |
| play              | make                  |
| pose              | be                    |
| want              | turn                  |
| pack              | open                  |
| steak             | take                  |
| push              | put                   |
| call              | get                   |
| pad               | find                  |
| explains          | give                  |
| read              | bring                 |
| hear              | want                  |
| Mean              | Mean                  |

Figure 6: Similarity with the base profile for Alternating and Non-alternating verbs

that verbs have stronger preferences. We use the cosine measure to estimate the similarity between two profiles  $p$  and  $q$ :

$$\text{similarity}(p, q) = \frac{p \cdot q}{\|p\| \cdot \|q\|} \quad (9)$$

The similarity values for the Alternating and Non-alternating verbs in Figure 6 show that the verbs represent more similarity with the base profile, which means a weaker selective preference.

The means for the Alternating and Non-alternating verbs were respectively 0.76 and 0.81, which confirms the hypothesis that the parameters of the direct object alternation select more strongly for the direct objects than verbs that do not. However, like Rensink (1996), we find that it is not possible to set a threshold that will distinguish the two sets of verbs.

## 5 Conclusions


We have proposed a cognitively plausible model for learning selectional preferences from instances of verb usage. The model represents verb selectional preferences as a semantic profile, which is a probability distribution over the semantic properties that an argument can take. One of the strengths of our model is that it can learn incrementally and online, in contrast to other approaches which learn selectional preferences in batch mode. Here we have only reported the results for the final stage of learning, but the model allows us to monitor the semantic

profiles during the course of learning, and compare it with child data for different age groups, as we do with semantic roles (Alshabani and Stevenson, 2007). We have shown that the model can predict appropriate semantic profiles for a variety of arguments, and use profiles to simulate human judgments of verb-argument plausibility, using a small and highly noisy set of training data. The model can also use the profiles to measure verb-argument compatibility, which was used in analyzing the implicit object alternation.

## References

- Alshabani, A. and Light, M. (1999). Hidden semantic hierarchy and semantic roles. In *Proc. of the 1st Workshop on Discourse-Level Learning in Computational Linguistics*.
- Alshabani, A. and Stevenson, S. (2005). A computational usage-based model for learning general properties of semantic roles. In *Proc. of the 2005 Conference on Empirical Methods in Natural Language Processing*.
- Anderson, J. R. (1991). The adaptive nature of human categories. *Cognition*, 39:141–170.
- Baker, C. L. and Lapata, M. (2003). Uniting and combining approaches to selectional preference induction. In *Proc. of the ECAI-2003*.
- Choi, Y. and Roth, M. (2006). Explaining away ambiguity: Learning with selectional preference with Bayesian classifiers. In *Proc. of the 2006 Conference on Empirical Methods in Natural Language Processing*.
- Choi, Y. and Roth, M. (2005). Classification probability estimation using a semantic hierarchy. *Computational Linguistics*, 28(2):171–192.
- Goldberg, M. (1995). Head-Driven Statistical Models for Natural Language Parsing. Ph.D. thesis, University of Pennsylvania.
- Hawkins, V. M., Stow, L., and Capello, L. (1999). Lexical constraints on argument selection: Evidence from the verb *know*. *Journal of Memory and Language*, 38:68–89.
- Lewis, B. (1993). English with clauses and adverbials: A perspective on the semantics of the verb *know*. *Language*, 69:103–124.
- Li, H. and Abe, N. (1998). Generating case frames using a hierarchical model and the MDL principle. *Computational Linguistics*, 24(2):171–192.
- Light, M. and Griff, W. (2002). Statistical models for the induction and use of selectional preferences. *Cognitive Science*, 26:101–132.
- MacWhinney, B. (1995). The CHILDES project: Tools for analyzing talk. Lawrence Erlbaum.
- Milner, G. (1993). Words and language: An encyclopedic reference. Routledge.
- Nation, K., Marshall, J. M., and Ahrens, G. T. M. (2005). Investigating individual differences in children's inductive semantic comprehension using language-excluded eye movements. *J. of Experimental Child Psychol.*, 80:314–329.
- Renck, P. (1996). Selectional constraints: An information-theoretic model and its computational realization. *Cognition*, 61:127–159.


# Organización y Análisis de Información



<https://www.questionpro.com/blog/what-is-data-analysis/>

- Anteriormente era un proceso manual y tedioso
- Estaba restringido a la capacidad humana de procesar los datos
- Por ende, el artículo científico era suficiente para validar experimentos
- Las computadoras se han convertido en un vehículo para ampliar las capacidades de análisis humanas

# Organización y Análisis de Información



- Utilizamos programas computacionales para organizar, limpiar y analizar información
- Estos programas utilizan diferentes algoritmos, análisis estadístico para procesar datos
- Pueden contener **bugs**
- Los datos pueden estar **corruptos**

<https://www.questionpro.com/blog/what-is-data-analysis/>

“La informática es ahora una actividad cotidiana para todos los científicos, de una forma u otra, desde ejecutar estadísticas simples sobre datos empíricos hasta ejecutar simulaciones masivas en instalaciones informáticas de liderazgo.”

**Barba (2022)**

¿Cómo nos  
aseguramos que  
nuestros experimentos  
son **reproducibles**?

# Definición de Reproducibilidad

“Obtener resultados computacionales consistentes usando los mismos datos de entrada, pasos computacionales, métodos y código, y condiciones de análisis.”

National Academies of Sciences, Engineering, and Medicine (2019)

# Implicaciones

- En 2011, ESEC/FSE inició un experimento novedoso para una importante conferencia de software: dar a los autores la oportunidad de enviar para evaluación cualquier artefacto que acompañe a sus artículos
- Un experimento similar se ha llevado a cabo con éxito en varias conferencias más.
- Este documento describe los objetivos y la mecánica general de este proceso

# Implicaciones

- La definición indica que los datos y el código producido por investigadores deben de estar disponibles para otros investigadores
- No necesariamente se deben liberar con licencias Open Source
- Al no liberar los datos y código de los experimentos, otros investigadores no tienen muchas libertades sobre los datos
- Puede ser un proceso tedioso contactar a los autores para que provean la información
- ¿Qué pasa si son laboratorios rivales?

# Barba (2022)

## Defining the role of open source software in research reproducibility

Lorena A. Barba, the George Washington University, Washington D.C.

November 2021

### **Abstract**

Reproducibility is inseparable from transparency, as sharing data, code and computational environment is a pre-requisite for being able to retrace the steps of producing the research results. Others have made the case that this artifact sharing should adopt appropriate licensing schemes that permit reuse, modification and redistribution. I make a new proposal for the role of open source software, stemming from the lessons it teaches about distributed collaboration and a commitment-based culture. Reviewing the defining features of open source software (licensing, development, communities), I look for explanation of its success from the perspectives of connectivism—a learning theory for the digital age—and the language-action framework of Winograd and Flores. I contend that reproducibility engenders trust, which we routinely build in community via conversations, and the practices of open source software help us to learn how to be more effective learning (discovering) together, contributing to the same goal.

# Historia de FOSS

- Investigadores han estado involucrados desde la génesis del software de código abierto (OSS) hace unos 50 años
- Ejemplos
  - Unix en Bell Labs
  - Berkeley Software Distribution
  - Unix-compatible GNU system en el MIT
  - Linux por Linus Torvalds en la Universidad de Helsinki
- El término software de código abierto (open source software) se introdujo hace unos 24 años (Peterson, 2008)
- Open Source Initiative (OSI) estipula el cumplimiento de diez criterios, que incluyen no solo la disponibilidad del código fuente, sino también la vinculación de una licencia para usarlo, modificarlo y redistribuirlo libremente.

# Implicaciones de Open Source

- Simplemente ofreciendo el código no es suficiente
- Se debe incluir una licencia aprobada por el OSI
- Para todo trabajo creativo **copyright** es automáticamente asignado a tu código
- El beneficio clave de las licencias aprobadas por OSI es que los investigadores no necesitan una amplia capacitación legal o consultores para navegar estos problemas: las licencias están “**preempaquetadas**” y listas para usar
- Cuando se aplica al software de investigación, contribuye a la transparencia del flujo de trabajo computacional y la disponibilidad para que otros usen/modifiquen/redistribuyan el software, uno de los requisitos de la **reproducibilidad**

# Implicaciones de Open Source

- El desarrollo abierto conduce a una mejor calidad porque los usuarios pueden generar informes de errores conscientes de la fuente y cooperar con los desarrolladores
- Muchos grupos de investigación pueden trabajar en mejorar el proyecto
- Los investigadores no tienen que estar firmando NDAs ni nada por el estilo

# La Ciencia es una Conversación

- Conocimiento científico no solo se transfiere por artículos científicos
- Muchas ideas nacen de conversaciones entre investigadores
- La apertura (Openness) promueve redes ricas, comunidades animadas y conexiones fértiles. Y esto es bueno para la ciencia
- Los proyectos de software de código abierto y la cultura de sus comunidades tienen más que ofrecer que un esquema para garantizar la libertad de las restricciones de derechos de autor en el código compartido
- Las comunidades de código abierto han desarrollado plantillas para coordinar las acciones de diversos grupos de personas, con el objetivo de mejorar la comunicación y trabajar juntos de manera más efectiva.

Open Source + Investigación

# LLVM



- LLVM es un conjunto de tecnologías de compilador y cadena de herramientas
- Desarrollado en University of Illinois at Urbana–Champaign
- Por Chris Lattner y su tutor Vikram Adve
- Licencia UIUC (BSD-style), basada MIT/X11 y licencia BSD de 3 cláusulas
- Es la base de múltiples proyectos
  - Rust
  - Clang
  - Swift
  - Xcode
- Se maneja a través de una fundación: <https://foundation.llvm.org/>

# Compilador Soot

- Soot comenzó como un marco de optimización de Java.
- Actualmente se utiliza para analizar, instrumentar, optimizar y visualizar aplicaciones Java y Android.
- Licencia GNU Lesser General Public License v2.1
- Permite análisis estático de programas Java y Android

# Project Jupyter

- Creado a partir de IPython en 2014 por Fernando Pérez
  - Colombiano, Profesor de Estadística en la Universidad de UC Berkeley
- Se separó de IPython en 2014
- Se maneja a través de una fundación:  
<https://jupyter.org/about>
- IPython tiene licencia BSD



¿Preguntas?